

(演示案例，承诺书略)

应急调度策略 A/B 的公平比较：Simpson 反转的识别与混杂校正

摘 要

针对某市两套应急调度派遣策略 A、B 的优劣评估问题，本文基于 700 条出警记录（字段：策略 policy、呼叫严重度 severity、是否按时到达 on_time），建立“描述 → 质疑 → 校正”三层递进的统计分析框架，识破合并率陷阱并给出可落地的公平比较方案。

针对问题一（哪套按时率更高），本文建立**边际（合并）率比较模型**，用两比例差 z 检验求解，得合并按时率 A 为 0.8286、B 为 0.5200，率差 +30.86 个百分点（95% CI [24.30, 37.41] pp, $p < 10^{-15}$ ）。表面看 A 远高于 B；但本文随即论证：**此结论是混杂误导的陷阱，不可据此向市政推荐 A**——这正是题目设计的反面教材。

针对问题二（结论是否可靠、有无混杂误判），本文建立**分层比较模型**并提出可证伪的 **Simpson 反转判定准则**（合并方向与每个层内方向均相反即成立），按 severity 分层求解。结果：合并口径 A 高，但**轻案层 B 0.94 > A 0.90、重案层 B 0.45 > A 0.40，两层方向一致地 B 高**，反转判定为真。混杂机制清楚：A 仅 14.3% 接重案、B 高达 85.7% 接重案（失衡 6.0 倍），合并率把“案件难度差”误算成“策略效果差”。这是教科书级 Simpson 悖论在本数据上的真实发生。

针对问题三（公平比较的正确做法与落地建议），本文以直接标准化率差为主、Mantel-Haenszel 合并 OR 与 logistic 回归为印证，三法交叉校正 severity。求解得：标准化率差（总体权）B 较 A 优 +4.5 pp（95% bootstrap CI [-3.83, +12.67] pp）、MH-OR(A/B)= 0.7527（95% CI [0.4378, 1.2941]）、logistic 校正 OR(B/A)= 1.323（95% CI [0.7728, 2.265]， $p = 0.31$ ）。三法点估计方向一致地指向 **B 略优**。但须如实指出：**三法的 95% 区间均跨过各自零值（率差含 0、OR 含 1、 $p > 0.05$ ），效应未达统计显著**。故本案最强且唯一可防守的结论是：**在给定可观测严重度下，校正后 B 不劣于 A、点估计略优约 4–5 pp，但在 $n = 700$ 、最小格 $n = 50$ 下尚不足以判定“B 显著更优”；而“用合并率推荐 A”几乎确定是错误方向**。本文进一步把“未达显著”量化为决策语言：功效反算给出达可判定所需样本量（总量约 $N = 3412$ ）、E-value (1.566) 量化结论对未观测混杂的脆弱性、TOST 区分“无效应 vs 样本不足”，并据此给市政过渡期可执行的行动规则。

灵敏度方面，标准化率差在总体权 / A 人群权 / B 人群权三套权重下恒为负（B 优），漂移仅约 0.7 pp，方向对权重稳健；Breslow-Day ($p = 0.615$) 与 logistic 交互项 ($p = 0.617$) 均不显著，层间效应同质，支持合并 OR；bootstrap 重跑数值逐位可复现。

本文创新点在于把“公平”操作化为“同等案件难度下比较”，提出可向市政一句话讲清的“**难度配平比较法**（severity-matched fair comparison）”，并以流行病学的人口标准化作类比；同时全程严守“方向 $\neq$ 显著、相关 $\neq$ 因果”的措辞红线，不把点估计优势夸大为显著优势或因果效应。

关键词：Simpson 悖论；混杂校正；直接标准化率；Mantel–Haenszel 合并 OR；logistic 回归

目录

1 问题重述	5
2 问题分析与基本假设	5
2.1 问题分析	5
2.2 基本假设（每条含理由与代价）	5
3 符号说明	6
4 模型的建立	6
4.1 Q1 · 边际（合并）率比较模型——基线，疑混杂误判	6
4.2 Q2 · 分层比较 + Simpson 反转判定准则	7
4.3 Q3 · 公平比较三法（控制 severity）	7
5 模型的求解与结果	7
5.1 Q1 · 合并率（陷阱基线）	8
5.2 Q2 · 分层 + Simpson 反转	8
5.3 Q3 · 公平比较三法（控制 severity）	9
5.4 Q3+ · 弱效应招式箱：把“未达显著”量化成决策价值	10
6 灵敏度分析	11
7 模型的评价	11
7.1 优点	11
7.2 局限性（如实写入 Critic 审计裁决）	12
7.3 本案自纠留痕	12
7.4 改进方向	12
8 结论	12
A 附录	13

1 问题重述

某市试点两套应急调度派遣策略 A 与 B，在一段时期内记录了每次出警的三个字段：本次采用的策略 `policy` (A / B)、呼叫严重度 `severity` (Low 轻 / High 重)、是否在目标时限内到达 `on_time` (1 是 / 0 否)。数据为 `data/dispatch.csv`，共 700 行，由确定性脚本生成、字节级可复现。要求回答：

- **Q1**：哪套策略的“按时到达率”更高？应向市政推荐哪一套？
- **Q2**：这个结论可靠吗？是否存在混杂导致的误判？
- **Q3**：若要公平比较两套策略，正确的做法是什么？给出可落地建议。

用自己的话归纳，本题的实质并非“算一个率”，而是**识破合并率在混杂下的误导，给出剔除混杂后可信的策略比较与落地建议**。三问层层递进（描述 Q1 → 质疑 Q2 → 校正 Q3）构成一条自纠链：Q1 的“直觉答案”预期与 Q3 的“正确方向”相反，这是题目考点而非数据错误。变量角色：`policy` 是处理变量 (`treatment`)，`on_time` 是结果变量 (`outcome`)，`severity` 是疑似混杂 (`confounder`)——它既可能影响“用哪套策略”，又直接影响“是否按时”。

2 问题分析与基本假设

2.1 问题分析

核心判断是 `severity` 同时关联处理与结果，构成混杂结构：若不控制它，合并率会把“案件难度差”误当“策略效果差”。因此分析路径定为三层：先给 Q1 的合并率作为“陷阱基线”；用分层检验混杂是否真导致反转 (Q2)；用标准化 / 合并 OR / 回归三法在控制 `severity` 后做公平比较 (Q3)。是否真混杂、反转是否真发生，均由数据实证，不预设。

2.2 基本假设（每条含理由与代价）

- **A1**：`severity` 是唯一相关、可控的混杂。理由：数据仅 3 字段。代价：现实可能有时段/路况/警力等**未观测混杂**，本数据无法测——结论只能限定在“给定可观测变量”下，**不可声称因果**。
- **A2**：每行是一次独立出警，可直接计数算率。理由：`call_id` 1..700 唯一连续、无重复。代价：若存在时间自相关，CI 偏窄。
- **A3**：`on_time` 口径在 A、B 间一致。理由：题面把 `on_time` 当统一结果字段。代价：若两策略各自定义时限则不可比；数据内无法验证。

- **A4**: 样本对该市出警总体有代表性。理由：题面要求向市政推荐。代价：试点期记录可能有**选择偏差**，外推受限。
- **A5**: **severity** 划分客观、两策略间含义一致。理由：作为分层依据必须可比。代价：若 **severity** 判定内生于 **policy**，分层/标准化失效；数据内无法验证。
- **A6**: 二值结果用率 / 卡方 / logistic 即可。理由：无时间戳、无机理过程。代价：若关心响应时间分布则丢信息。

A1、A5 是最该被质疑、也最关键的两条，下文模型评价中如实写入其不可验证性。

3 符号说明

符号	含义
$T \in \{A, B\}$	处理变量 (policy)
$S \in \{L, H\}$	混杂变量 (severity: Low / High)
$Y \in \{0, 1\}$	结果变量 (on_time)
n_{ts}	策略 t 、层 s 的样本数
y_{ts}	策略 t 、层 s 的按时数
$\hat{p}_{ts} = y_{ts}/n_{ts}$	层内按时率
$\hat{p}_t$	策略 t 的合并 (边际) 按时率
w_s	标准化层权重 ($w_L + w_H = 1$)
$\hat{p}_t^{\text{std}} = \sum_s w_s \hat{p}_{ts}$	标准化率
$\widehat{OR}_{MH}$	Mantel-Haenszel 合并比值比
β_1	logistic 中 B 相对 A 的对数几率差 (控制 S)

锁定的单元计数 (数据实测):

	n_{tL}	$\hat{p}_{tL}$	n_{tH}	$\hat{p}_{tH}$	合并率 $\hat{p}_t$
A	300	0.9000	50	0.4000	0.8286
B	50	0.9400	300	0.4500	0.5200

4 模型的建立

4.1 Q1 · 边际 (合并) 率比较模型——基线，疑混杂误判

统计量为合并按时率 $\hat{p}_t = \sum_s y_{ts} / \sum_s n_{ts}$ ，比较 $\hat{p}_A$ 与 $\hat{p}_B$ ，用两比例差 z 检验：

$$z = \frac{\hat{p}_A - \hat{p}_B}{\sqrt{\hat{p}(1 - \hat{p})(1/N_A + 1/N_B)}}, \quad \hat{p} = \frac{y_A + y_B}{N_A + N_B}.$$

为什么选它：这是 Q1 字面问的口径，作为“陷阱基线”先给出直觉答案，才能在 Q2 推翻它。**代价：**完全忽略 severity，在 A 偏轻案、B 偏重案的失衡下会误判，故标注“待审计/疑混杂误判”，**不作推荐依据。**

4.2 Q2 · 分层比较 + Simpson 反转判定准则

层内率 $\hat{p}_{As}, \hat{p}_{Bs}$ 各带 Wilson 置信区间。设合并方向 $d_0 = \text{sign}(\hat{p}_A - \hat{p}_B)$ 、层内方向 $d_s = \text{sign}(\hat{p}_{As} - \hat{p}_{Bs})$ ，定义可证伪的反转准则：

$$\text{反转成立} \iff d_0 \neq d_L \text{ 且 } d_0 \neq d_H.$$

混杂判定三条件：(1) S 关联 T ($P(H|A) = 0.143 \neq P(H|B) = 0.857$)；(2) S 关联 Y ($P(Y|L) = 0.906 \neq P(Y|H) = 0.443$)；(3) S 为前置难度而非中介（依赖 A5）。**代价：**层内最小格 $n = 50$ ，分层率有抽样波动，必须带 CI。

4.3 Q3 · 公平比较三法（控制 severity）

(a) **直接标准化率差**（主结论，市政语言最直观）：选统一层权重 w_s ，

$$\hat{p}_t^{\text{std}} = \sum_s w_s \hat{p}_{ts}, \quad \Delta^{\text{std}} = \hat{p}_A^{\text{std}} - \hat{p}_B^{\text{std}},$$

主权重取总体权 $w_L = w_H = 0.5$ ，并以 A 人群权、B 人群权作敏感性上下界；CI 用 bootstrap (seed=42, 1 万次)。

(b) **Mantel-Haenszel 合并 OR**（稳健性印证，对小格更稳）：各层 2×2 表层内 OR 加权合并

$$\widehat{OR}_{MH} = \frac{\sum_s a_s d_s / n_s}{\sum_s b_s c_s / n_s},$$

并用 Breslow-Day 检验层间 OR 是否同质（若显著则改报分层）。

(c) **logistic 回归**（可扩展性佐证）： $\text{logit } P(Y = 1) = \beta_0 + \beta_1 \mathbb{I}[T = B] + \beta_2 \mathbb{I}[S = H]$ ， e^{β_1} 为校正 OR，应与 MH-OR 互印证（注意 MH 是 A/B 编码、logistic 是 B/A 编码，方向需对齐）；加交互项检验效应异质性。三法估计量、尺度、稳健性不同但方向应一致，方向一致是放行的交叉验证点。

5 模型的求解与结果

复现：seed=42, bootstrap 10000 次；Python 3.14.3 / numpy 2.4.2 / pandas 3.0.2 / scipy 1.17.1 / statsmodels 0.14.6。求解前已通过 PoC 冒烟闸（三候选可跑通、量级合理、方向一致，输出 PASS 反转确认）。

5.1 Q1 · 合并率 (陷阱基线)

策略	按时数	总数	合并按时率	95% Wilson CI
A	290	350	0.8286	[0.7856, 0.8644]
B	182	350	0.5200	[0.4677, 0.5718]

率差 $A-B = +0.3086$ (+30.86 pp), 95% CI [0.2430, 0.3741], $z = 8.71$, $p < 10^{-15}$ 。合并口径 A 显著更高——但这是被混杂污染的描述统计，**严禁据此推荐 A**。

5.2 Q2 · 分层 + Simpson 反转

severity	策略	n	按时率	95% Wilson CI	层内差 A-B	差的 95% CI
Low	A	300	0.9000	[0.8608, 0.9291]	-0.0400	[-0.1141, +0.0341]
Low	B	50	0.9400	[0.8378, 0.9794]	(B 更高)	
High	A	50	0.4000	[0.2761, 0.5382]	-0.0500	[-0.1970, +0.0970]
High	B	300	0.4500	[0.3947, 0.5066]	(B 更高)	

合并方向 $d_0 = +$ (A 高), Low、High 层方向均为 $-$ (B 高), 判定 $d_0 \neq d_L$ 且 $d_0 \neq d_H \rightarrow$ **Simpson 反转成立 (True)**。




图 1: 合并 vs 分层按时率对比: 最右“合并”柱 A 高于 B, 而 Low、High 两组层内柱均 B 高于 A, 方向反转一目了然 (误差棒为 95% Wilson CI)。

不确定性如实交代: 两层内差的 95% CI 均跨 0 (Low [-0.114, +0.034], High [-0.197, +0.097])。

反转方向稳定（两层点估计均 B 高），但单层“B 高”在统计上不显著——最小格 $n = 50$ 使单层 CI 偏宽。反转作为“现象”成立；“B 在某层显著更优”则证据不足。




图 2: 混杂机制: A 接重案仅 14.3%、B 接重案达 85.7% (失衡 6.0 倍)。两策略几乎没接到同类难度构成的呼叫, 合并率把案件难度误差算成策略效果差。

混杂机制: A 接重案仅 14.3%、B 接重案达 85.7%, 失衡 **6.0 倍**; *severity* 边际效应 $P(Y|L) - P(Y|H) = 0.9057 - 0.4429 = 0.4629$ 。这是本案最扎实、最可解释的发现。

5.3 Q3 · 公平比较三法（控制 *severity*）

(a) 直接标准化率差（主权重 = 总体权 0.5/0.5）: 标准化率 $A = 0.6500$ 、 $B = 0.6950$, B 较 A 优 +4.5 pp, 95% bootstrap CI $[-3.83, +12.67]$ pp (含 0)。

(b) Mantel-Haenszel 合并 OR: $OR(A/B) = 0.7527$ ($< 1 \rightarrow B$ 优), 95% CI $[0.4378, 1.2941]$ (含 1); Breslow-Day $\chi^2 = 0.2525$ ($p = 0.6154$) $\rightarrow$ 层间 OR 同质。

(c) logistic 回归 (A, Low 为参照):

系数	估计	OR	95% CI(OR)	<i>p</i>
policy=B (控制 <i>severity</i>)	$\beta_1 = +0.2799$	1.3230	$[0.7728, 2.2650]$	0.3075
<i>severity</i> =High	$\beta_2 = -2.6964$	0.0675	—	$< 10^{-15}$

$OR(B/A) = 1.323 > 1$ (B 几率更高), 与 MH 互印证 ($1/0.7527 = 1.329 \approx 1.323$, 方向对齐正确); 交互项 $p = 0.617$ (不显著) $\rightarrow$ 无显著效应异质性, 与 Breslow-Day 一致。




图 3: 三法森林图: 标准化率差、MH-OR、logistic OR 点估计方向一致地指向 B 略优, 但 95% 区间均跨过各自零值。

方法	统计量	指向 B 优?
(a) 标准化率差 (主权重)	$A-B = -4.5 \text{ pp} < 0$	是
(b) MH-OR(A/B)	$0.7527 < 1$	是
(c) logistic OR(B/A)	$1.323 > 1$	是

三法点估计方向一致地指向 B 略优。但三法的 95% 区间均跨过各自零值 (率差含 0、OR 含 1、logistic $p = 0.31$), 无一达 $\alpha = 0.05$ 。故唯一可防守的结论是: 校正 severity 后, B 不劣于 A、点估计略优约 4–5 pp, 但在 $n = 700$ 、最小格 $n = 50$ 下未达统计显著; 据此不足以让市政在 A/B 间做出有把握的优选, 但足以证明“用合并率推荐 A”是错误方向。三法是同一批数据的三种换算, 并非三份独立证据, 不能用“方向一致”反推“统计显著”。

5.4 Q3+ · 弱效应招式箱: 把“未达显著”量化成决策价值

三法 95% 区间均跨零、属“方向稳健但未达显著”。本文不停在“做不出结论”, 以三招把不确定性量化 (绝不夸大显著):

招	量	结果
功效/样本量反算	达 80% 功效 ($\alpha = 0.05$ 双侧) 检出当前约 4.5 pp 标准化率差所需样本量	每组 $N = 1706$ (合计 3412), 现有 700; Cohen's $h = 0.096$
TOST 等效检验	实质等效边界 $\pm 5 \text{ pp} / \pm 10 \text{ pp}$ (先验设定)	$\pm 5 \text{ pp}$: $p = 0.45$ 不等效; $\pm 10 \text{ pp}$: $p = 0.10$ 不等效
E-value (因果稳健性)	推翻 logistic OR(B/A) = 1.323 方向所需未观测混杂强度 (结局常见, $RR \approx \sqrt{OR}$)	点估计 E-value = 1.566; 区间含零 $\rightarrow$ E-value(CI) = 1.0

三招一致表明“B 略优”是**方向稳健、强度证据不足**：既非“无效应”（招 1/2 显示是样本不足），方向又**对未观测混杂不稳健**（招 3：一个 $RR \approx 1.57$ 的未观测混杂即可解释掉它）。这把“未达显著”转译为**做出结论所需的样本量与结论的脆弱程度**，决策收口见第 7 节。

6 灵敏度分析

维度	设置	结果	稳健性
标准化权重	总体 / A 人群 / B 人群	$A-B \in [-4.86, -4.14]$ pp, 恒为负, 漂移约 0.7 pp	方向稳健, 强度 不敏感
层间效应同质	Breslow-Day + 交互项	$p = 0.6154 / p = 0.6170$, 均不显著	同质成立, 合并 OR 可用
最小格样本	High-A、Low-B 各 $n = 50$	单层差 CI 偏宽、跨 0	反转方向稳, 显著性不足
severity 边际效应	$P(Y L)$ $P(Y H)$	— 0.4629	混杂确强
bootstrap 复现	seed=42 重跑	数值逐位一致	可复现

核心结论：“校正后 B 略优”的方向对权重和层间同质假设都稳健（漂移仅 0.7 pp、两项同质检验均不显著）；但所有不确定性区间都跨零，强度上的“不显著”也同样稳健——稳健的是方向，不是显著性。

7 模型的评价

7.1 优点

(1) 叙事链完整且可证伪：Q1（陷阱）→ Q2（反转判定准则，0/1 可判定）→ Q3（三法校正），每步配“为什么选它”与代价。(2) 三法交叉印证 + 数值互验：MH-OR 倒数 $1/0.7527 = 1.329$ 与 logistic OR 1.323 互验，编码方向对齐正确。(3) 敏感性扎实：三套权重、双查同质、最小格标注、bootstrap 1 万次，全部可复现。(4) 创新落点可被引用、有方法增量：“难度配平比较法”把“公平 = 同等难度下比”讲成市政能懂的一句话，并进一步把“未达显著”操作化为决策量——功效反算给出达可判定所需样本量 ($N \approx 3412$)、E-value (1.566) 量化结论对未观测混杂的脆弱性、TOST 区分“无效应 vs 样本不足”，相对“仅做三法校正”是实打实的方法增量。

7.2 局限性（如实写入 Critic 审计裁决）

本文严守独立审计（Critic）红线，不藏短板：

1. **效应未达统计显著（最重要的诚实）**：三法 95% 区间均跨零（率差含 0、MH-OR 含 1、logistic $p = 0.31$ ），两层内差也都不显著（Low $p = 0.290$ 、High $p = 0.505$ ）。故“B 显著优于 A / 推荐市政采用 B / B 胜出”在本数据下不成立；本文只主张“校正后 B 不劣于、点估计略优、未达显著”。
2. **不可声称因果**：数据仅 3 字段，时段/路况/警力等未观测混杂无法排除（A1），severity 判定是否独立于 policy 数据内无法验证（A5）。所有结论仅在“给定可观测 severity 下、关联层面”成立，不得写“B 导致更高按时率”。
3. **样本量与功效**：效应量小（约 4–5 pp / $OR \approx 1.32$ ，Cohen's $h = 0.096$ ），最小格 $n = 50$ ，功效不足——功效反算显示达 80% 功效需总样本约 $N = 3412$ （现有 700），TOST 在 ± 5 pp 下亦不能判等效，故属“样本不足”而非“无效应”；“五个角度点估计同号”在效应方向一致而强度微弱时本就常见，不等于显著。
4. **外推受限**：样本为试点期记录，无时间/区域字段，选择偏差无法验证（A4）。
5. **口径未核实项**：on_time 跨策略时限一致性（A3）、severity 判定独立性（A5）数据内均无法证伪，仅能标注待核实。

7.3 本案自纠留痕

本案由 ModelCrew 子代理端到端真跑。Critic 不信任散文，独立写脚本从原始 CSV 重算全部关键量逐项核对 results.json：所有数字经得起独立复算，无造假、无除零、无 NaN，反转真实成立。同时揪出早期散文 4_results.md 中 3 处旧版残留数字（logistic β_{sevH} 旧值 -2.494 应为 -2.6964 、交互项 p 旧值 0.964 应为 0.617 、A 的 Wilson CI 旧值 $[0.7847, 0.8650]$ 应为 $[0.7856, 0.8644]$ ），已据 results.json 为唯一真值同步修正；三处均不改变任何结论方向。本文所有数字与 frozen_numbers.json / results.json 同源。

7.4 改进方向

采集并纳入时段、路况、出动警力等候选混杂做更充分的回归调整或倾向得分匹配；若条件允许，对呼叫做随机化派遣可从根本上消除混杂、支持因果结论；扩大样本量以提升对约 4–5 pp 小效应的统计功效。

8 结论

(1) Q1 的合并率是陷阱，不可据此推荐 A：合并按时率 $A = 0.8286$ 远高于 $B = 0.5200$ ，但这是 A 专挑轻案、B 专挑重案（失衡 6.0 倍）造成的混杂假象。(2) Q2 混杂

确实导致误判，Simpson 反转真实发生：分层后两层内均 B 高于 A，与合并方向相反；但单层“B 高”未达统计显著。(3) **Q3 公平比较应控制 severity**：三法点估计一致指向 B 略优（约 4-5 pp / $OR \approx 1.32$ ），方向对权重稳健，**但效应未达统计显著**。

给市政的决策导向收口（不确定性下仍可执行的三段式行动规则，仅由结果支持）：

1. **立即停用合并按时率做 A/B 考核**——它因案件难度构成不同而系统性误导（6 倍失衡），几乎确定推荐错策略。**此条结论是显著的、可硬下定论**。
2. **过渡期默认**：若必须二选一，可暂用“难度配平口径下点估计占优、且对权重稳健（漂移仅 0.7 pp）”的 **B 作为暂定默认**——但须明示**暂定、非定论**：B 仅点估计略优约 4-5 pp，三法区间均跨零、未达显著，且方向对未观测混杂不稳健（**E-value 仅 1.566**）。
3. **启动可判定的下一步**：对呼叫**随机化派遣**以根除混杂、支持因果结论；据功效反算，达 80% 功效检出当前约 4.5 pp 效应需**总样本约 $N = 3412$** （现有 700），即约需扩样本 5 倍或采集一个完整随机化周期。

即：本案唯一能向市政硬下的定论是“别用合并率推荐 A”；“选 B”只能作带 caveat 的过渡期默认，不替市政把“B 显著更优”写成定论。

参考文献

- [1] Simpson, E. H. The Interpretation of Interaction in Contingency Tables. *Journal of the Royal Statistical Society, Series B*, 1951, 13(2): 238-241.
- [2] Mantel, N., Haenszel, W. Statistical Aspects of the Analysis of Data from Retrospective Studies of Disease. *Journal of the National Cancer Institute*, 1959, 22(4): 719-748.
- [3] Rothman, K. J., Greenland, S., Lash, T. L. *Modern Epidemiology*. 3rd ed. Lippincott Williams & Wilkins, 2008.
- [4] Agresti, A. *Categorical Data Analysis*. 3rd ed. Wiley, 2013.

A 附录

复现信息：代码 `solve.py`(python `solve.py`, 绝对路径定位数据)；数据 `data/dispatch.csv`, MD5=496fd5aafdbbcc3f11edba376d5f2331（运行时实时校验）；随机种子 `seed=42`, bootstrap `N_BOOT=10000` (`numpy.random.default_rng(42)`，分层 4 格各自有放回重采样)。CI 方法：单比例 Wilson；两比例差 Wald；标准化率差 bootstrap 百分位；MH-OR Robins-Breslow-Greenland 方差；logistic Wald CI。弱效应招式箱：功效/样本量反

算 (`statsmodels.stats.power`, Cohen's h , 每组 $N = 1706$ 、合计 3412); TOST 两单侧检验 (边界 $\pm 5/\pm 10$ pp); E-value (结局常见用 $RR \approx \sqrt{OR}$, $E = 1.566$, 区间含零故 $E\text{-value}(CI) = 1$)。图: `figures/fig1_simpson_reversal.png`, `fig2_confounding_imbalance.png`, `fig3_three_methods_forest.png`。数字唯一真值源: `frozen_numbers.json / results.json`。**产出说明:** 本文由 ModelCrew 子代理端到端真跑产出 (Router 定题 $\rightarrow$ Analyst 审题 $\rightarrow$ Scout 数据体检 $\rightarrow$ Modeler 选模型 $\rightarrow$ Solver 真跑求解 $\rightarrow$ Critic 独立复算审计 $\rightarrow$ Writer 成稿)。所有数字与 `frozen_numbers.json / results.json` 同源, 未另造。本 `.tex` 已用 **MiKTeX xelatex 编译通过** (`6_paper.pdf`, 13 页, 无未定义引用); 复现: `xelatex 6_paper.tex` (跑两遍)。